

Калинин Никита

Москва, Россия | nktkln@nktkln.com | 8 (966) 976-94-25 | nktkln.com | t.me/nktkln_work
github.com/NKTKLN

О себе

Junior ML Engineer: классический и табличный ML, прикладная математика и production-инжиниринг на Python. Реализую ML-алгоритмы и алгоритмы векторного поиска (HNSW, LSH) с нуля и подтверждаю бенчмарками против scikit-learn/XGBoost (расхождение в тысячных долях метрики); строю end-to-end пайплайны для Kaggle (Spaceship Titanic 0.805) с feature engineering и Optuna-тюнингом.

К ML-навыкам прилагается реальный production-backend опыт: асинхронный backend LLM-ассистента с агентным OpenAI tool-calling и вычислительный REST-сервис на FastAPI с кэшированием. Строгая типизация (mypy strict), security-аудит зависимостей, воспроизводимые окружения, CI. Соавтор двух научных публикаций и зарегистрированной программы для ЭВМ.

Проекты

Code Kata — ML-алгоритмы с нуля и Kaggle-пайплайны

Личный ML-проект: классические алгоритмы машинного обучения, реализованные с нуля на Python/NumPy и подтвержденные бенчмарками против библиотечных реализаций, плюс end-to-end пайплайны для Kaggle-соревнований.

Репозиторий: github.com/NKTKLN/code-kata

- Реализовал с нуля gradient boosting (с ручным выводом градиентов), random forest, деревья решений, bagging, stacking, kNN, линейную и логистическую регрессию; бенчмарки подтвердили точность на уровне scikit-learn/XGBoost (расхождение в тысячных долях метрики).
- Построил end-to-end пайплайны для Kaggle (Spaceship Titanic — 0.805, Titanic — 0.782): EDA, доменный feature engineering, сравнение CatBoost/LightGBM/XGBoost и Optuna-тюнинг (TPE, 150 trials, GPU).
- Реализовал и сравнил 4 алгоритма приближенного поиска ближайших соседей (HNSW, LSH, k-d trees, Annoy-подобный индекс) по точности, скорости и памяти — основа vector search в RAG-системах.

AI Notes API — асинхронный backend LLM-ассистента над заметками

Личный backend-проект для LLM-ассистента над приватными заметками: асинхронный FastAPI-сервис с RAG по загруженным документам, агентным циклом OpenAI tool-calling, долгосрочной памятью диалога и фоновой генерацией.

- Спроектировал асинхронный сервис на FastAPI + async SQLAlchemy 2.0 / PostgreSQL по слоистой архитектуре (api / services / repositories); довел покрытие до 89.5% line / 83.1% branch (456 тестов) при строгом mypy и CI на Postgres + Redis.
- Реализовал агентный цикл OpenAI tool-calling с реестром из 5 CRUD-инструментов: модель сама ищет и изменяет заметки пользователя в рамках одного диалога.
- Устранил гонки при параллельной генерации, заменив read-modify-write на атомарный UPDATE ... WHERE status=IDLE ... RETURNING — ровно одна активная генерация на сессию без распределенных локов.
- Построил RAG-пайплайн для grounded-ответов по документам: extraction (MarkItDown) → token-chunking с overlap (tiktoken) → эмбединги OpenAI → векторный поиск по косинусной дистанции в PostgreSQL/pgvector (top-5 чанков).

QUICK — Вычислительный backend-сервис моделирования МИИС

Исследовательско-инженерный проект (постановка — в соавторстве, весь код и 144 коммита — мои): REST API и веб-интерфейс над вычислительным ядром для моделирования медицинских ИИС.

Репозиторий: github.com/NKTKLN/quick

- Реализовал три взаимозаменяемых вычислительных движка за единым интерфейсом (паттерны Factory и Strategy): аналитический (спектральное разложение), численный (уравнения Колмогорова, SciPy solve_ivp / RK45) и Монте-Карло симуляцию — выбор движка под требования к точности и скорости расчета.
- Создал гибридный решатель NumPy + mpmath с автоматическим обнаружением численно нестабильных участков и их пересчетом с произвольной точностью — примерно в 2 раза быстрее полного расчета в высокой точности и без потери корректности результата.

Навыки

Языки программирования: Python (строгая типизация, mypy strict), SQL, Go (базовый backend-опыт)

AI/ML: scikit-learn, XGBoost, CatBoost, LightGBM, Optuna, реализация ML-алгоритмов с нуля, кросс-валидация и подбор гиперпараметров, оценка моделей (ROC/PR, confusion matrix), vector search (HNSW, LSH, pgvector); LLM-интеграция (OpenAI), RAG, embeddings, tool-calling, structured output, prompt engineering

Данные: pandas, NumPy, SciPy, feature engineering, EDA, Matplotlib, Seaborn, Plotly, Streamlit

Backend: FastAPI, async SQLAlchemy 2.0, Pydantic v2, REST API, JWT-аутентификация, Celery, SSE, Alembic, кэширование, слоистая архитектура

Базы данных: PostgreSQL, Redis, MongoDB, SQLite, DuckDB, MinIO

DevOps и инструменты: Docker (multi-stage), CI/CD, Git, Linux, uv, Taskfile, pre-commit, ruff, gitleaks, pip-audit

Тестирование: pytest, coverage

Публикации

Проектирование веб-сервиса для оценки качества медицинских информационно-измерительных систем

Архитектура decision-support веб-сервиса для расчета характеристик системы и рекомендаций по конфигурации МИИС.

Дворецкий А.Г., Барабанова Е.А., Калинин Н.В.

Модель медицинской информационно-измерительной системы, основанной на беспроводной оптической технологии передачи данных

Математическая модель МИИС на основе Li-Fi, теории массового обслуживания и анализа переходных режимов.

Дворецкий А.Г., Барабанова Е.А., Калинин Н.В.

Достижения

Государственная регистрация программы для ЭВМ № 2026661833

Апр 2026

Соавтор программного комплекса для моделирования и анализа информационно-измерительных систем медицинского назначения (проект QUICK).

Образование

МИРЭА — Российский технологический университет, Информационные системы и технологии

Сен 2023 – Июнь 2027

- Институт перспективных технологий и индустриального программирования
- Средний балл: 5.0 / 5.0; профиль — full-stack, развиваюсь в ML / AI-инфраструктуре

Языки

Русский: Родной

Английский: B2 — техническая документация и инженерная коммуникация