

Калинин Никита

Москва, Россия | nktkln@nktkln.com | 8 (966) 976-94-25 | nktkln.com | t.me/nktkln_work
github.com/NKTKLN

О себе

Junior AI Backend / ML Engineer: Python, FastAPI, ML и сильная база в прикладной математике. Разрабатываю backend-сервисы и ML-системы полного цикла: REST API с валидацией и кэшированием, RAG-сервис с векторным поиском, Docker-развертывание, реализация ML-алгоритмов с нуля с бенчмарками против scikit-learn/XGBoost.

Production-подход в каждом проекте: строгая типизация (mypy strict), структурированное логирование, security-аудит зависимостей, воспроизводимые окружения, conventional commits. Соавтор двух научных публикаций и зарегистрированной программы для ЭВМ.

Проекты

AI Notes API — RAG-сервис для семантического поиска по заметкам

Личный AI backend-проект (в активной разработке): REST API для ведения заметок с семантическим поиском и LLM-ответами на вопросы по собственным данным через RAG-пайплайн.

- Разрабатываю backend на FastAPI: JWT-аутентификация, CRUD-эндпоинты с Pydantic-валидацией, обработка ошибок и автогенерируемая OpenAPI-документация.
- Реализую RAG-пайплайн: построение embeddings, векторное хранилище для семантического поиска по заметкам и генерация ответов LLM с опорой на найденный контекст.
- Использую PostgreSQL как основное хранилище и Redis для кэширования; сервис контейнеризован в Docker.
- Веду проект с тестами (pytest) и CI/CD-пайплайном: линтинг, проверка типов и прогон тестов на каждое изменение.

QUICK — Вычислительный backend-сервис моделирования МИИС

Исследовательско-инженерный проект (математическая постановка — в соавторстве, весь код — мой, 144 коммита): REST API и веб-интерфейс вокруг вычислительного ядра для моделирования медицинских информационно-измерительных систем реального времени (~7,5 тыс. строк Python). Архитектура inference-сервиса: запрос → валидация → вычислительный движок → кэшированный структурированный ответ.

Репозиторий: github.com/NKTKLN/quick

- Спроектировал versioned REST API на FastAPI: Pydantic-валидация на уровне схем и домена, корректная обработка ошибок (422/500), health-check и OpenAPI-документация.
- Реализовал три взаимозаменяемых вычислительных движка за единым интерфейсом (паттерны Factory и Strategy): аналитический (спектральное разложение), численный (уравнения Колмогорова, SciPy solve_ivp / RK45) и Монте-Карло симуляцию.
- Создал гибридный решатель NumPy + mpmath с автоматическим обнаружением численно нестабильных участков и их пересчетом с произвольной точностью — примерно в 2 раза быстрее расчета целиком в высокой точности без потери корректности.
- Разработал декоратор кэширования тяжелых вычислений в DuckDB с семантическим ключом и graceful degradation: сбой кэша не ломает обработку запроса.
- Устранил риск выполнения произвольного кода при десериализации кэша, реализовав SafeUnpickler с белым списком классов.
- Подготовил multi-stage Docker-сборку (uv, non-root user, healthcheck) и слоистую архитектуру (domain / services / db / api / web): одно ядро обслуживает REST API и Streamlit-интерфейс с Plotly-визуализацией.

Code Kata — ML-алгоритмы с нуля и Kaggle-пайплайны

Личный ML-проект: классические алгоритмы машинного обучения, реализованные с нуля на Python/NumPy и подтвержденные бенчмарками против библиотечных реализаций, плюс end-to-end пайплайны для Kaggle-соревнований.

Репозиторий: github.com/NKTKLN/code-kata

- Реализовал с нуля gradient boosting (с ручным выводом градиентов), random forest, деревья решений, bagging, stacking, kNN, линейную и логистическую регрессию; бенчмарки подтвердили точность на уровне scikit-learn/XGBoost (расхождение в тысячных долях метрики).
- Реализовал и сравнил 4 алгоритма приближенного поиска ближайших соседей (HNSW, LSH, k-d trees, Annoy-подобный индекс) по точности, скорости и памяти — основа vector search в RAG-системах.
- Построил end-to-end пайплайны для Kaggle (Spaceship Titanic — 0.805, Titanic — 0.782): EDA, доменный feature engineering, обработка пропусков, сравнение CatBoost/LightGBM/XGBoost и Optuna-тюнинг (TPE sampler, 150 trials, кросс-валидация).
- Разработал переиспользуемую типизированную библиотеку оценки моделей (ROC/PR-кривые, confusion matrices, feature importance) с Google-style docstrings.
- Настроил инфраструктуру качества: ruff (16+ групп правил), mypy strict, pre-commit, security-аудит зависимостей (pip-audit, deptry), conventional commits с автоверсионированием.

Навыки

Языки программирования: Python (строгая типизация, mypy strict), SQL, Go (базовый backend-опыт)

Backend: FastAPI, Pydantic v2, REST API, JWT-аутентификация, OpenAPI/Swagger, кэширование, структурированное логирование (loguru), паттерны проектирования, слоистая архитектура

AI/ML: scikit-learn, XGBoost, CatBoost, LightGBM, Optuna, RAG, embeddings, vector search (HNSW, LSH), LLM-интеграция, оценка моделей, кросс-валидация

Данные: pandas, NumPy, SciPy, feature engineering, препроцессинг, EDA, Matplotlib, Seaborn, Plotly, Streamlit

Базы данных: PostgreSQL, Redis, MongoDB, SQLite, DuckDB, MinIO

DevOps и инструменты: Docker (multi-stage), CI/CD, Git, Linux, uv, Taskfile, pre-commit, ruff, gitleaks, pip-audit

Тестирование: pytest, coverage

Публикации

Проектирование веб-сервиса для оценки качества медицинских информационно-измерительных систем

Архитектура decision-support веб-сервиса для расчета нестационарных характеристик производительности системы, хранения результатов моделирования и формирования рекомендаций по конфигурации МИИС.

Дворецкий А.Г., Барабанова Е.А., Калинин Н.В.

Модель медицинской информационно-измерительной системы, основанной на беспроводной оптической технологии передачи данных

Математическая модель МИИС с использованием Li-Fi, основанная на аппарате теории массового обслуживания и анализе переходных режимов.

Дворецкий А.Г., Барабанова Е.А., Калинин Н.В.

Достижения

Государственная регистрация программы для ЭВМ № 2026661833

Апр 2026

Соавтор программного комплекса для моделирования и анализа информационно-измерительных систем медицинского назначения (проект QUICK).

Kaggle

Spaceship Titanic — score 0.805; Titanic — score 0.782.

Образование

МИРЭА — Российский технологический университет, Информационные системы и технологии Сен 2023 – Июнь 2027

Профиль подготовки: full-stack разработка; дополнительно развиваюсь в ML Engineering и AI-инфраструктуре.

- Институт перспективных технологий и индустриального программирования
- Кафедра индустриального программирования
- Средний балл: 5.0 / 5.0

Языки

Русский: Родной

Английский: B2 — свободно читаю техническую документацию, использую английский в инженерной коммуникации