

Калинин Никита

Москва, Россия | nktkln@nktkln.com | 8 (966) 976-94-25 | nktkln.com | t.me/nktkln_work
github.com/NKTKLN

О себе

Junior AI Backend / ML Engineer: Python, FastAPI, ML и сильная база в прикладной математике. Разрабатываю backend-сервисы и ML-системы полного цикла: асинхронный backend LLM-ассистента с агентным OpenAI tool-calling, вычислительный REST-сервис с кэшированием, реализация ML-алгоритмов и алгоритмов векторного поиска (HNSW, LSH) с нуля с бенчмарками против scikit-learn/XGBoost.

Production-подход в каждом проекте: строгая типизация (mypy strict), security-аудит зависимостей, воспроизводимые окружения, conventional commits. Соавтор двух научных публикаций и зарегистрированной программы для ЭВМ.

Проекты

AI Notes API — асинхронный backend LLM-ассистента над заметками

Личный backend-проект для LLM-ассистента над частными заметками (в активной разработке): асинхронный FastAPI-сервис с агентным циклом OpenAI tool-calling, долгосрочной памятью диалога и фоновой генерацией.

- Спроектировал асинхронный сервис на FastAPI + async SQLAlchemy 2.0 / PostgreSQL по слоистой архитектуре (api / services / repositories); довел покрытие до ~92% (376 тестов) при строгом mypy и CI на Postgres + Redis.
- Реализовал агентный цикл OpenAI tool-calling с реестром инструментов: модель сама ищет и изменяет заметки пользователя через CRUD-инструменты в рамках одного диалога.
- Устранил гонки при параллельной генерации, заменив read-modify-write на атомарный UPDATE ... WHERE status=IDLE ... RETURNING — ровно одна активная генерация на сессию без распределенных локов.

QUICK — Вычислительный backend-сервис моделирования МИИС

Исследовательско-инженерный проект (математическая постановка — в соавторстве, весь код — мой, 144 коммита): REST API и веб-интерфейс вокруг вычислительного ядра для моделирования медицинских информационно-измерительных систем (~7,5 тыс. строк Python).

Репозиторий: github.com/NKTKLN/quick

- Реализовал три взаимозаменяемых вычислительных движка за единым интерфейсом (паттерны Factory и Strategy): аналитический (спектральное разложение), численный (уравнения Колмогорова, SciPy solve_ivp / RK45) и Монте-Карло симуляцию.
- Создал гибридный решатель NumPy + mpmath с автоматическим обнаружением численно нестабильных участков и их пересчетом с произвольной точностью — примерно в 2 раза быстрее расчета целиком в высокой точности без потери корректности.
- Спроектировал версионированный REST API на FastAPI (Pydantic-валидация, обработка ошибок 422/500, OpenAPI), multi-stage Docker-сборку (non-root, healthcheck) и слоистую архитектуру: одно ядро обслуживает REST API и Streamlit-интерфейс с Plotly-визуализацией.

Code Kata — ML-алгоритмы с нуля и Kaggle-пайплайны

Личный ML-проект: классические алгоритмы машинного обучения, реализованные с нуля на Python/NumPy и подтвержденные бенчмарками против библиотечных реализаций, плюс end-to-end пайплайны для Kaggle-соревнований.

Репозиторий: github.com/NKTKLN/code-kata

- Реализовал с нуля gradient boosting (с ручным выводом градиентов), random forest, деревья решений, bagging, stacking, kNN, линейную и логистическую регрессию; бенчмарки подтвердили точность на уровне scikit-learn/XGBoost (расхождение в тысячных долях метрики).
- Реализовал и сравнил 4 алгоритма приближенного поиска ближайших соседей (HNSW, LSH, k-d trees, Annoy-подобный индекс) по точности, скорости и памяти — основа vector search в RAG-системах.
- Построил end-to-end пайплайны для Kaggle (Spaceship Titanic — 0.805, Titanic — 0.782): EDA, доменный feature engineering, сравнение CatBoost/LightGBM/XGBoost и Optuna-тюнинг (TPE, 150 trials, GPU).

Навыки

Языки программирования: Python (строгая типизация, mypy strict), SQL, Go (базовый backend-опыт)

Backend: FastAPI, async SQLAlchemy 2.0, Pydantic v2, REST API, JWT-аутентификация, Celery, SSE, Alembic, кэширование, логирование (loguru), слоистая архитектура

AI/ML: scikit-learn, XGBoost, CatBoost, LightGBM, Optuna, vector search (HNSW, LSH), LLM-интеграция (OpenAI), tool-calling, structured output, prompt engineering

Данные: pandas, NumPy, SciPy, feature engineering, EDA, Matplotlib, Seaborn, Plotly, Streamlit

Базы данных: PostgreSQL, Redis, MongoDB, SQLite, DuckDB, MinIO

DevOps и инструменты: Docker (multi-stage), CI/CD, Git, Linux, uv, Taskfile, pre-commit, ruff, gitleaks, pip-audit

Тестирование: pytest, coverage

Публикации

Проектирование веб-сервиса для оценки качества медицинских информационно-измерительных систем

Архитектура decision-support веб-сервиса для расчета нестационарных характеристик системы и формирования рекомендаций по конфигурации МИИС.

Дворецкий А.Г., Барабанова Е.А., Калинин Н.В.

Модель медицинской информационно-измерительной системы, основанной на беспроводной оптической технологии передачи данных

Математическая модель МИИС с использованием Li-Fi, основанная на аппарате теории массового обслуживания и анализе переходных режимов.

Дворецкий А.Г., Барабанова Е.А., Калинин Н.В.

Достижения

Государственная регистрация программы для ЭВМ № 2026661833

Апр 2026

Соавтор программного комплекса для моделирования и анализа информационно-измерительных систем медицинского назначения (проект QUICK).

Kaggle

Spaceship Titanic — score 0.805; Titanic — score 0.782.

Образование

МИРЭА — Российский технологический университет, Информационные системы и технологии

Сен 2023 – Июн 2027

- Институт перспективных технологий и индустриального программирования, кафедра индустриального программирования
- Средний балл: 5.0 / 5.0; профиль — full-stack, развиваюсь в ML / AI-инфраструктуре

Языки

Русский: Родной

Английский: B2 — техническая документация и инженерная коммуникация